

BURSA TEKNİK ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
Bilgisayar Mühendisliği Bölümü



İsim ve Öbeklerin Saptanması (Chunking)

Doğal Dil İşleme — Proje Konusu 3 · Türkçe için CRF Tabanlı Öbekleme

Dr. Öğr. Üyesi HAYRİ VOLKAN AGUN

Doğal Dil İşleme — BLM0467

Mustafa Can Ersoy
20360859046

Haziran 2026
Bursa Teknik Üniversitesi · Bilgisayar Mühendisliği Bölümü · 2025–2026 Bahar

Özet

Ne yaptık? Verilen bir Türkçe cümlede yer alan öbekleri (isim NP, eylem VP, sıfat ADJP, zarf ADVP, edat PP) ve yan cümlecikleri (RELCL, COMPCL, ADVCL) otomatik olarak işaretleyen, dizisel etiketleme temelli bir *chunking* (sığ ayrıştırma) sistemi geliştirdik. Tüm işaretlemeler CoNLL / BIO biçimindedir. **Neler kullandık?** Veri Universal Dependencies Türkçe-IMST treebank'inden türetilmiş; model olarak istatistiksel CRF (*Conditional Random Fields*) kullanılmış; öznitelik çıkarımı ve değerlendirme Python (scikit-learn, sklearn-crfsuite, sequeval, matplotlib) ile yapılmıştır. Sistem ana görevde **kelime düzeyinde 88.6% doğruluk** ve **öbek düzeyinde 0.838 F1** elde etmiştir.

Anahtar Kelimeler: Chunking, CRF, Dizisel Etiketleme, CoNLL/BIO, Türkçe Doğal Dil İşleme.

GitHub: github.com/MustafaCanErsoy/turkish-chunking-crf

1. Problem Tanımı

Bir cümle, tek tek kelimelerden değil, anlamlı kelime gruplarından oluşur: bir isim ile onu niteleyen sözcükler bir isim öbeği, bir eylem ile yardımcıları bir eylem öbeği oluşturur. Chunking (sığ ayrıştırma), cümleyi tam bir sözdizimsel ağaca ayrıştırmadan bu temel öbekleri bulup sınıflandırma görevidir. Tam ayrıştırmaya göre daha hızlı ve hatalara karşı daha dayanıklı olduğundan; bilgi çıkarımı, varlık tanıma ve makine çevirisi gibi uygulamalarda sık kullanılan bir ön işleme adımıdır.

Bu çalışmada iki katmanlı bir işaretleme yapılmıştır. Birincil katman olan **CHUNK**, beş temel öbeği ayırt eder: isim öbeği (NP), eylem öbeği (VP), sıfat öbeği (ADJP), zarf öbeği (ADVP) ve edat öbeği (PP). İkincil katman olan **CLAUSE** ise cümle içindeki yan cümlecikleri kapsar: ilgi cümlecigi (RELCL), tümleş cümlecigi (COMPCL) ve zarf cümlecigi (ADVCL).

Her iki katman da **BIO şeması** ile kodlanır. Bu şemada bir öbeğin ilk kelimesi B- (başlangıç), sonraki kelimeleri I- (iç) ve hiçbir öbeğe girmeyen kelimeler O (dışında) etiketini alır; böylece öbek sınırları kelime dizisi üzerinde belirsizliğe yer bırakmadan gösterilebilir. Örneğin “Dün toplantıdan çıkan öğrenci” parçasında “Dün” tek başına bir zarf öbeğidir (B-ADVP), “toplantıdan çıkan öğrenci” ise tek bir isim öbeği oluşturur (B-NP, I-NP, I-NP). Bu kodlama sayesinde problem, her kelimeye bir etiket atanan bir **dizisel etiketleme (sequence labeling)** problemine dönüşür.

2. Kullanılan Yöntemler ve Araçlar

2.1 Veri ve İşaretleme

Türkçe için elle işaretlenmiş hazır bir chunking veri kümesi bulunmadığından, eğitim ve test verisi açık lisanslı Universal Dependencies **Türkçe-IMST treebank**'inden türetilmiştir. Bu treebank her cümle için sözcük türlerini (POS) ve kelimeler arasındaki bağımlılık ilişkilerini içerir. Bağımlılık ağacı üzerinde tanımladığımız dilbilgisi kurallarıyla, bir baş kelime ile ona bağlı sözcüklerin oluşturduğu öbekler ve cümleciklerin kapsamı otomatik olarak BIO etiketlerine çevrilmiştir. Elde edilen veri toplam **3435 eğitim** ve **1100 test** cümlesi içermekte ve CoNLL biçiminde proje dosyasında yer almaktadır.

2.2 Öznitelikler

Modelin her kelime için kullandığı öznitelikler yüzeysel ve bağlamsaldır: kelimenin kendisi, baştaki ve sondaki 1–4 harfli ekleri, büyük/küçük harf deseni, POS etiketi ve hemen çevresindeki iki komşuya kadar olan kelimelerin sözcük ve POS bilgileri. Türkçe sondan eklemeli bir dil olduğu için son ekler öbek türü hakkında güçlü ipuçları taşır; örneğin “-da/-de” eki çoğu zaman bir ismin, dolaylı olarak bir isim öbeğinin sonunu, fiil çekim ekleri ise bir eylem öbeğini işaret eder. Bu nedenle ek temelli öznitelikler başarıda belirleyici rol oynar.

2.3 Model


Sınıflandırıcı olarak **CRF (Conditional Random Fields)** seçilmiştir. CRF, her kelimeyi tek tek sınıflandırmak yerine cümlelerin tüm etiket dizisini birlikte değerlendirir ve etiketler arasındaki geçiş kurallarını da öğrenir. Böylece “I-NP yalnızca B-NP ya da I-NP'den sonra gelebilir” gibi kısıtları kendiliğinden uygulayarak geçersiz etiket dizilerini önler; bu da onu BIO tabanlı öbeikleme için doğal ve güçlü bir seçim yapar. Model, `sklearn-crfsuite` kütüphanesiyle L-BFGS optimizasyonu ve L1/L2 düzenleme kullanılarak eğitilmiştir. Toplam üç model eğitilmiştir: ham metni işaretleyebilmek için bir POS etiketleyici, ana görev için **CHUNK** modeli ve yan cümlecikler için **CLAUSE** modeli. Değerlendirme ve grafikler `scikit-learn`, `sequeval` ve `matplotlib` ile üretilmiştir.

3. Sonuçlar (Çıktılar)

Ana görev olan chunking için test kümesinde sınıf bazında öbek (entity) düzeyi başarı değerleri Tablo 1'de verilmiştir.


Öbek	Precision	Recall	F1	Adet
NP	0.839	0.842	0.841	3020
VP	0.853	0.895	0.873	1727
ADJP	0.625	0.634	0.630	454
ADVP	0.943	0.937	0.940	461
PP	0.721	0.637	0.676	146
Genel (micro)	0.832	0.844	0.838	5808

Tablo 1. Chunking sınıf bazında başarı. Kelime düzeyi doğruluk: **88.6%**; genel öbek F1: **0.838** (P=0.832, R=0.844).



1. Karışıklık matrisi (her sınıf, normalize) — Chunking.

Şekil



Şekil 2. Sınıf bazında F1 değerleri — Chunking.

Sonuçlar incelendiğinde, en yüksek başarı sınırları belirgin olan zarf ve isim öbeklerinde elde edilmiştir; zarf öbekleri çoğunlukla tek kelimeden oluştuğu için neredeyse kusursuz ayrılır. Buna karşılık sıfat ve edat öbekleri daha zordur: sıfatlar çoğu zaman bir isim öbeğinin içinde yer aldığından model onları sık sık isim öbeğiyle karıştırır. Bu durum Şekil 1'deki karışıklık matrisinde ADJP ile NP arasındaki karışma olarak açıkça görülmektedir. Edat öbeklerinin görece az sayıda örnekle temsil edilmesi de bu sınıftaki başarıyı sınırlamaktadır.

Tablo 2, tüm görevlerin özetini sunar. Gerçekçi “uçtan uca” senaryoda, modele hazır POS etiketi verilmez ve POS da sistemin kendisi tarafından tahmin edilir; bu durumda öbek F1'i 0.838'den 0.756'e düşer. Bu düşüş, doğru POS bilgisinin öbekleme için ne kadar değerli olduğunu somut biçimde ortaya koyar. Yan cümlecik (CLAUSE) katmanı ise en zorlu görevdir: cümlecikler uzun ve çoğu zaman iç içe geçen kapsamlar oluşturduğundan, tam kapsam eşleşmesi gerektiren öbek F1'i düşük kalır; yine de kelime düzeyindeki doğruluk (78.6%) makul bir seviyededir.

Görev	Kelime Doğruluğu	Öbek F1
POS etiketleme	91.2%	—
Chunking (gold POS)	88.6%	0.838
Chunking (uçtan uca, tahmini POS)	82.4%	0.756
Clause (yan cümlecik)	78.6%	0.278

Tablo 2. Tüm görevlerin özet başarı karşılaştırması.

4. Örnek Çıktı ve Sonuç

Eğitilmiş sistemin ham bir cümleye ürettiği uçtan uca çıktı (*Öğrenci kütüphanede yeni kitabı okudu.*):

#	Kelime	POS	CHUNK	CLAUSE
1	Öğrenci	NOUN	B-NP	O
2	kütüphanede	NOUN	B-NP	O
3	yeni	ADJ	B-NP	O
4	kitabı	NOUN	I-NP	O
5	okudu	VERB	B-VP	O
6	.	PUNCT	O	O

Sonuç olarak, Türkçe için CRF tabanlı bir öbekleme sistemi geliştirilmiş ve eğitim ile test süreçlerini uçtan uca yürüten çalışır bir boru hattı kurulmuştur. Ana görevde kelime düzeyinde 88.6% doğruluk ve öbek düzeyinde 0.838 F1 elde edilmiş; tüm işaretlemeler CoNLL/BIO biçiminde üretilmiş ve her sınıf için başarı oranları ile karışıklık matrisi raporlanmıştır. Çalışmanın başlıca sınırlılığı, etiketlerin bir treebank'ten kurallarla türetilmiş olmasıdır. İleride elle işaretlenmiş veri, morfolojik öznitelikler (örneğin Zemberek çözümlemeleri) veya kelime vektörleri eklenerek ve özellikle sıfat/edat öbekleri ile cümlecik katmanına odaklanılarak başarının daha da artırılması mümkündür.